УДК 004.942

Шарашева Н. И.

Прогнозирование распространенности онкологических заболеваний

Рекомендовано к публикации доцентом Лежниной Е. А.

1. Введение. В большинстве стран с высоким и средним уровнем экономического развития онкологические заболевания занимают первые позиции среди причин смерти людей. В России они занимают 2 место месте после болезней системы кровообращения, при этом заболеваемость раком возрастает в среднем на 2–3% в год.

Прогнозирование заболеваемости онкологией играет ключевую роль в современном здравоохранении, позволяя не только оценивать будущую динамику болезни, но и разрабатывать эффективные стратегии профилактики, диагностики и лечения. Точные прогнозы необходимы для оптимального планирования медицинской инфраструктуры и распределения ресурсов, а также помогают оценить экономическое бремя рака для общества, включая затраты на лечение и потери трудоспособности.

2. Обзор методов. Данные о заболеваемости и смертности представляют собой временной ряд, основным источником которого являются статистические ежегодники [1]. Историческая глубина доступных данных ограничена 30 – 40 годами, что существенно снижает эффективность применения сложных моделей, таких как глубокие нейронные сети или гауссовские процессы. В условиях ограниченного объема выборки такие модели подвержены риску переобучения, что приводит к снижению их обобщающей способности. В подобных сценариях они не всегда обеспечивают значимое преимущество в точности прогноза по сравнению с более простыми статистическими методами, которые оказываются более устойчивыми и надёжными при работе с малым числом наблюдений.

Одним из самых распространенных методов для прогнозирования одномерных временных рядов являются модели скользящего среднего ARIMA(p, d, q) [2], [3]. Эта модель сочетает три компонента:

Шарашева Надежда Ильдаровна – студент, Санкт-Петербургский государственный университет; e-mail: st097214@student.spbu.ru, тел.: +7(917)883-07-83

авторегрессию (AR), интегрированный компонент (I) и скользящее среднее (MA).

Авторегрессия учитывает зависимость текущего значения ряда от предыдущих наблюдений. Интегрированный компонент устраняет тренд путем дифференцирования, что делает ряд стационарным. Скользящее среднее описывает зависимость текущего значения от ошибок прошлых предсказаний, и учитывает краткосрочные отклонения от общей тенденции.

Модель зависит от 3 гиперпараметров: p – порядок авторегрессии, d – порядок дифференцирования и q – порядок скользящего среднего. ARIMA применяется для стационарных временных рядов, но может быть адаптирована для работы с нестационарными данными за счёт включения дифференцирования ($d > 0$), что подробно описано в работе [4]. Также эффективно показывают себя модели экспоненциального сглаживания Холта – Уинтерса [5].

В работе [6] рассмотрено прогнозирование распространения пандемии COVID-19 с помощью интегральной модели притока-оттока. Также данная модель была использована для прогнозирования численности населения Земли в работе [7]. Предлагается использовать аналогичный подход для построения прогнозов распространенности неинфекционных заболеваний, используя онкологию в качестве примера.

3. Модель для прогноза численности населения, подверженного онкологическим заболеваниям. Интегральная модель притока и оттока описывает динамику численности пациентов с онкологическими заболеваниями в популяции, учитывая приток новых случаев (диагностированные пациентов) и отток (умершие и выздоровевшие пациенты). Модель основана на принципе динамического баланса, согласно которому общее количество пациентов в любой момент времени определяется разницей между числом вновь выявленных случаев и числом пациентов, выбывших из группы больных. В случае онкологических заболеваний будем рассматривать только число умерших пациентов в качестве оттока, поскольку при выходе в ремиссию сохраняется риск повторного заболевания, и пациенту необходимо продолжать наблюдения у врача, т. е. пациент не выходит из группы больных.

Пусть $X(t)$ – число людей, подвергнувшихся онкологическим заболеваниям в момент времени t. В каждый момент времени посту-

пает $x_{\text{inf}}(t)$ новых пациентов и выбывает $x_{\text{of}}(t)$ пациентов. Тогда состояние системы можно описать дискретным уравнением

$$X(t) = X(t-1) + x_{\text{inf}}(t) - x_{\text{of}}(t).$$

Приток и отток пациентов являются стохастическими процессами, поэтому эволюция системы $X(t)$ становится случайным процессом, зависящим от временных рядов $x_{\text{inf}}(t)$ и $x_{of}(t)$.

Введем интегральные значения притока и оттока как суммы членов соответствующих временных рядов

$$X_{\text{inf}}(t) = \sum_{\tau=t_0}^{t} x_{\text{inf}}(\tau), \quad X_{\text{of}}(t) = \sum_{\tau=t_0}^{t} x_{\text{of}}(\tau).$$

Тогда основное уравнение модели примет вид

$$X(t) = X(t_0) + X_{\text{inf}}(t) - X_{\text{of}}(t).$$

Для анализа динамики притока и оттока вводятся процентные приросты

$$r_{inf}(t) = 100\frac{X_{\text{inf}}(t) - X_{\text{inf}}(t-1)}{X_{\text{inf}}(t-1)},$$

$$r_{of}(t) = 100\frac{X_{\text{of}}(t) - X_{\text{of}}(t-1)}{X_{\text{of}}(t-1)}.$$

Рассмотрим модель, описывающую динамику онкологических заболеваний при $t > t_0$, представленную системой дискретных уравнений:

$$C(t) = \sum_{t=t_0+1}^{t} x_{\text{inf}}(t),$$

$$R(t) = \sum_{t=t_0+1}^{t} x_{\text{of}}(t).$$

$$I(t) = C(t) - R(t),$$

где $I(t)$ – число людей, подверженных заболеванию, $C(t)$ и $R(t)$ – это кумулятивные суммы новых случаев и смертей соответственно, начиная с момента времени t_0+1 до момента времени t. Для получения

прогнозов используются рекуррентные формулы

$$C(t) = \left(1 + \frac{r_{\text{inf}}(t)}{100}\right) C(t-1), \tag{1}$$

$$R(t) = \left(1 + \frac{r_{\text{of}}(t)}{100}\right) R(t-1), \tag{2}$$

$$I(t_0) = C(t_0) = R(t_0) = 0. \tag{3}$$

Параметрами модели являются процентный прирост количества выявленных случаев заболевания $r_{\text{inf}}(t)$ и процентный прирост количества смертей $r_{\text{of}}(t)$, изменяющиеся во времени.

Модель (1)–(3) является интегральной моделью притока–оттока пациентов с онкологическими заболеваниями.

4. Численный эксперимент. Был выполнен прогноз численности людей, подверженных онкологическим заболеваниям, на основе данных за 1993–2023 годы.

Точность модели оценивалась по предсказаниям количества пациентов на 2017–2023 года с помощью метрики

$$MAPE = \frac{1}{n} \sum_{t=1}^{n} \left| \frac{I(t) - \widehat{I}(t)}{I(t)} \right| 100\%.$$

Оценка *MAPE* ретроспективных прогнозов с помощью интегральной модели притока-оттока равна 9,5%. Для сравнения, сделан прогноз с помощью модели ARIMA(2,1,2). Процесс подбора гиперпараметров модели ARIMA начинается с определения порядка дифференцирования d. Для этого используется тест Дики – Фуллера, позволяющий выявить необходимость преобразования временного ряда в стационарный вид. После приведения ряда к стационарному состоянию осуществляется выбор порядка авторегрессии p — он определяется на основе графика частичной автокорреляционной функции, где ключевым ориентиром служит резкий спад значений. Аналогичным образом порядок компоненты скользящего среднего q устанавливается по автокорреляционной функции, анализируя тот лаг, на котором происходит значительное снижение корреляции. Значение MAPE для модели ARIMA(2,1,2) равно 11,09%.

Для прогнозирования заболеваемости на период 2023–2030 годы были построены аппроксимирующие степенные функции для параметров $r_{\text{inf}}(t)$ и $r_{\text{of}}(t)$ на основе данных за 1993–2023 годы. В таблице 1 приведены полученные функции и значения коэффициента детерминации, характеризующего качество аппроксимации и вычисленного по формуле

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \widehat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \overline{y})^2},$$

где y_i – реальные значения, $\widehat{y}_i$ – предсказанные моделью значения, $\overline{y}$ – среднее значение исходных данных, n – количество наблюдений.

Таблица 1. Аппроксимация параметров на период 2023-2030

Параметр	**Аппроксимирующая функция**	$\mathbf{R^2}$
$r_{\text{inf}}(t)$	$94{,}2x^{-0{,}93}$	0,9989
$r_{\text{of}}(t)$	$97{,}957x^{-0{,}874}$	0,9981

Таблица 2. Прогноз на период 2023-2030

Дата	**ИП, чел.**	**Прирост ИП, %**	**ИО, чел.**	**Прирост ИО, %**	**I(t), чел.**
2023	15346067	3,30064	9993779	4,0455	5352288
2024	15912409	3,690471	10467218	4,737338	5445191
2025	16482909	3,585252	10949927	4,611628	5532982
2026	17057510	3,486042	11441892	4,492860	5615618
2027	17636158	3,392335	11943100	4,380463	5693058
2028	18218801	3,303683	12453539	4,273927	5765262
2029	18804541	3,215031	12972527	4,167391	5832014
2030	19392442	3,126379	13499322	4,060855	5893120

5. Заключение. Результаты проведенных вычислительных экспериментов подтвердили высокую эффективность интегральной модели притока-оттока для прогнозирования распространенности онкологических заболеваний. Эта модель дала более точные прогнозы по сравнению с методами, основанными на модели ARIMA, что позволяет делать более обоснованные выводы о будущем развитии ситуации.

В таблице 2 представлен прогноз на период 2023–2030 годы, который показывает устойчивый рост численности пациентов с онкологическими заболеваниями, что подчеркивает необходимость дальнейшего развития стратегий профилактики, диагностики и лечения.

Полученные результаты можно использовать для оценки демографического и экономического ущербов, путем расчета экономического бремени заболевания и количества потерянных лет человеческих жизней.

Литература

1. Заболеваемость онкологией и смертность от нее с 1997 года // МНИОИ им. П.А. Герцена; обработка «Если быть точным», 2024. [Электронный ресурс]: URL:https://tochno.st/datasets/cancer_incidence (дата обращения: 17.10.24).

2. Jian Y., Zhu D., Zhou D. ARIMA model for predicting chronic kidney disease and estimating its economic burden in China // BMC Public Health. 2022. No 22. [Электронный ресурс]: URL:https://doi.org/10.1186/s12889-022-14959-z (дата обращения: 24.10.24).

3. Оленев Р. О. Прогнозирование фондовых индексов с использованием моделей ARIMA и LSTM // Процессы управления и устойчивость. 2023. Т. 10. No 1. С. 304–308.

4. Box G. E. P., Jenkins G. M., Reinsel G. C., Greta M. L. Time Series Analysis Forecasting and Control. New Jersey: John Wiley and Sons Inc., 2015. 712 p.

5. Wang N., Zhuang W., Ran Z. et al. Prediction of acute onset of chronic cor pulmonale: comparative analysis of Holt-Winters exponential smoothing and ARIMA model // BMC Med. Res. Methodol. 2024. No 204. [Электронный ресурс]: URL:https://doi.org/10.1186/s12874-024-02325-z (дата обращения: 24.10.24).

6. Балыкина Ю. Е., Захаров В. В. Интегральная модель притока и оттока и ее приложения // Вестник Санкт-Петербургского университета. Прикладная математика. Информатика. Процессы управления. 2024. Т. 20. No 2. С. 121–135.

7. Аникушин В. А., Редько А. Ю. Применение модели ARIMA для прогнозирования численности населения Земли // Процессы управления и устойчивость. 2024. Т. 11. No 1. С. 229–306.